

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Vinícius Augusto Landim Andrade (RA: 169251)

Repositório / Código Reprodutível:

<https://github.com/vinicius-landim/neural-networks-course/tree/main/mlp/src>

1. Configuração Experimental e Reprodutibilidade

1.1. Pré-processamento e Partição dos Dados (se necessário)

A partição dos dados seguiu estritamente a proporção de 10% para treino, 10% para validação e 80% para teste. Essa restrição intencional no volume de treino torna a tarefa suscetível ao sobreajuste, tornando a investigação de hiperparâmetros e técnicas de regularização crítica. As amostras selecionadas para treino podem ser observadas na figura 1.




Figure 1: Função original vs Amostra de treino

O pré-processamento incluiu a padronização dos atributos por distribuição através do `StandardScaler` da biblioteca `scikit-learn`. Para assegurar a integridade do experimento e mitigar qualquer vazamento de dados (*data leakage*), o cálculo das médias e desvios-padrão (*fit*) ocorreu exclusivamente sobre as 30 amostras do conjunto de treino. Posteriormente, as métricas de escalonamento foram aplicadas (*transform*) de forma isolada às partições de validação e teste.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* consiste em uma rede *Multi-Layer Perceptron* (MLP) básica, implementada em PyTorch e treinada estritamente com o algoritmo de otimização SGD (sem aceleradores adaptativos como Adam e com termo de *momentum* igual a 0.0). Nenhuma regularização explícita (L1, L2 ou Dropout) foi aplicada nesta fase inicial, estabelecendo um ponto de partida puramente não-regularizado.

A busca empírica pela melhor configuração baseou-se na variação da profundidade da rede e na largura das camadas densas. Vale ressaltar que as escolhas para o Modelo Baseline foram feitas avaliando os resultados para treino e validação, sendo o conjunto de teste verificado somente após a definição da arquitetura.

A topologia final selecionada para o baseline (e mantida para os estudos de ablação) é composta por três camadas ocultas com 64, 128 e 64 neurônios, respectivamente, intercaladas por funções de ativação ReLU. O treinamento utilizou *mini-batches* de 5 amostras e uma taxa de aprendizado (η) fixada em 0.01 ao longo de 5.000 épocas. Os melhores pesos foram salvos através de um *checkpoint* do modelo no menor Erro Quadrático Médio (MSE) alcançado no conjunto de validação.

A Tabela 1 detalha o espaço de hiperparâmetros explorado e a configuração final selecionada.

Table 1: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida (Vanilla)
Topologia das Camadas	1, 2 e 3 camadas ocultas; 16, 32, 64 e 128 neurônios	Entrada $\rightarrow$ 64 $\rightarrow$ 128 $\rightarrow$ 64 $\rightarrow$ Saída
Função de Ativação	ReLU, Tanh	ReLU
Otimizador	SGD puro (sem <i>momentum</i>)	SGD ($\eta = 0.01$)
Tamanho do Lote (<i>Batch Size</i>)	5, 10, 30 amostras	5
Função de Custo	Erro Quadrático Médio (MSE)	MSE
Treinamento e Seleção	5.000 épocas; monitoramento pelo menor MSE de validação	5.000 épocas (resgate do melhor <i>checkpoint</i>)
Semente Aleatória	Sementes fixas para reprodutibilidade	<code>seed = 42</code>

O modelo *Vanilla* atingiu seu ponto ótimo de convergência na época 2422. As métricas registradas neste *checkpoint* foram:

- **Métricas no Treinamento:** MSE = 0.1007, RMSE = 0.3173 e MAE = 0.2444
- **Métricas na Validação:** MSE = 0.3046, RMSE = 0.5519 e MAE = 0.4420

Observe a existência de uma discrepância entre os erros, com o MSE de validação sendo aproximadamente três vezes maior que o de treinamento. Isso representa um caso de *overfitting*, sendo esse comportamento esperado dado o tamanho restrito dos dados de treino e a arquitetura definida.

2. Dinâmica de Treinamento e Convergência (Baseline vs. Modificados)

A evolução das curvas de função de perda (MSE) e da métrica auxiliar (MAE) ao longo das épocas foi monitorada para verificar a estabilidade do otimizador e comparar a dinâmica do *baseline* com os modelos submetidos ao estudo de ablação. As figuras 2, 3, 4, 5 e 6 ilustram essas trajetórias.




Figure 2: Convergência da MLP Baseline (Vanilla).

Treinamento - Baseline + Momentum




Figure 3: Convergência da MLP Baseline com Momentum ($\beta = 0.9$).

Treinamento - Baseline + L2




Figure 4: Convergência da MLP Baseline com Regularização L2 ($\lambda = 10^{-6}$).

Treinamento - Baseline + L1




Figure 5: Convergência da MLP Baseline com Regularização L1 ($\lambda = 10^{-5}$).




Figure 6: Convergência da MLP Baseline com Dropout ($p_1 = 0.1, p_2 = 0.05$).

2.1. Análise Crítica da Dinâmica de Convergência:

2.1.1 Estabilidade do SGD

Na Figura 2, as perdas de treino e validação apresentam oscilações persistentes. Esse comportamento reflete a limitação do SGD puro com taxa de aprendizado constante: sem reduzir o passo ao se aproximar do mínimo, o modelo sofre contínuo *overshooting*. Além disso, aplicar uma taxa uniforme a todo o espaço de parâmetros gera saltos excessivos nas direções íngremes (causando o ruído) e progresso lento nas regiões suaves. A ausência de mecanismos de suavização, como o *momentum*, faz com que essas instabilidades fiquem evidentes nas curvas ao longo do treinamento."

2.1.2 Sobreajuste (*Overfitting*)

Na Figura 2, observa-se que os erros de treino e validação se descolaram logo nas primeiras épocas. No decorrer das épocas, observou-se uma intensificação do *overfitting*, visto que o custo de validação passou a crescer e, mesmo com uma queda próxima da época 1500, a curva se estabilizou em uma *loss* muito maior em comparação com o conjunto de treino.

2.1.3 Aceleração com Momentum:

Na Figura 3, observou-se que a inclusão do momentum reduziu de forma clara o número de épocas necessárias para a *loss* de treino atingir valores baixos. Vale ressaltar que as escalas verticais das Figuras 2 e 3 são distintas, porém, a partir da evolução da MAE, observa-se que com momentum o modelo atingiu uma *loss* de 0.2 em uma época muito anterior a obtida com o SGD padrão. Essa aceleração ocorre porque o momentum acumula a direção dos gradientes anteriores, de modo que, nas direções em que o gradiente é consistente, os passos se somam e a taxa de aprendizado efetiva aumenta. Em contrapartida, a mesma velocidade acumulada dificulta a "frenagem" dos pesos, que passam do ponto ideal, o que se manifesta como picos abruptos de erro, sobretudo na validação, com valores de MSE de 2 a 4, bem acima do máximo observado no baseline.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar rigorosamente o efeito de cada componente, a arquitetura base (camadas, ativações e sementes) foi mantida idêntica à da Tabela 1, avaliando-se as seguintes variações individuais:

1. **Baseline + Momentum:** SGD com fator de momentum de $\beta = 0.9$.

2. **Baseline + Regularização L2 (Weight Decay):** Penalização quadrática dos pesos, com $\lambda_{L2} = 10^{-6}$.
3. **Baseline + Regularização L1 (Lasso):** Penalização por norma L_1 para incentivo à esparsidade, com $\lambda_{L1} = 10^{-5}$.
4. **Baseline + Dropout:** Desativação aleatória de neurônios em ambas as camadas ocultas, com $p_1 = 0.05$ e $p_2 = 0.1$.
5. **Modelo Combinado:** Baseline + Momentum ($\beta = 0.9$) + Regularização L2 ($\lambda_{L2} = 10^{-6}$).

3.1. Análise no Conjunto de Desenvolvimento (Treino e Validação)

A seleção dos hiperparâmetros e do melhor ponto de treinamento foi realizada com base no menor erro quadrático médio (MSE) observado no conjunto de validação, correspondente a 10% dos dados. Embora o treinamento tenha sido executado por 5000 épocas, os pesos correspondentes à época de menor MSE de validação foram armazenados e posteriormente utilizados na avaliação do conjunto de teste. Esse procedimento corresponde à seleção do melhor *checkpoint*, não a uma interrupção antecipada do treinamento.

A Tabela 2 sumariza o comportamento de convergência e os erros de ajuste de cada configuração.

Table 2: Resultados do Estudo de Ablação: convergência nos conjuntos de treino e validação.

Modelo / Variação	Época Ideal	MSE (Tr)	MSE (Val)	MAE (Tr)	MAE (Val)
Baseline Vanilla (SGD)	2422	0.1007	0.3046	0.2444	0.4420
Baseline + Momentum ($\beta = 0.9$)	2705	0.0777	0.2422	0.2138	0.3960
Baseline + Reg. L1 ($\lambda = 10^{-5}$)	2611	0.1227	0.3045	0.2843	0.4359
Baseline + Reg. L2 ($\lambda = 10^{-6}$)	2611	0.1231	0.2994	0.2828	0.4310
Baseline + Dropout ($p_1 = 0.05$, $p_2 = 0.1$)	4786	0.1191	0.3128	0.2747	0.4568
Modelo Combinado	3215	0.0499	0.2869	0.1730	0.4359

A análise empírica da etapa de desenvolvimento demonstra que o maior ganho observado esteve associado a introdução isolada do *Momentum*, que apresentou o menor MAE de validação (0.3960), superando o *baseline*. A respeito das regularizações L1 e L2, elas resultaram em uma diminuição mínima da *loss* de validação em relação ao *baseline* (0.4420), com MAE de 0.4359 e 0.4310, respectivamente.

As regularizações também produziram aumento moderado do erro de treinamento, comportamento compatível com a restrição imposta à magnitude dos pesos. O *Dropout*, por sua vez, apresentou MAE de validação de 0.4568 e atingiu seu melhor *checkpoint* apenas na época 4786. Esse resultado indica que, para o conjunto de treinamento reduzido utilizado neste experimento, a configuração de *Dropout* adotada não produziu melhora na validação em relação ao *baseline*.

O Modelo Combinado apresentou o menor erro de treinamento (MAE = 0.1730), mas não obteve o menor erro de validação, com MAE de validação de 0.4359.

3.2. Desempenho de Generalização (Conjunto de Teste)

A avaliação definitiva da capacidade de generalização dos modelos foi realizada sobre os 80% dos dados correspondentes ao conjunto de teste (240 amostras). Esses dados permaneceram estritamente isolados e não influenciaram o ajuste dos pesos ou a seleção dos *checkpoints*. Os resultados finais são apresentados na Tabela 3.

Table 3: Desempenho final no conjunto de teste isolado (80% dos dados).

Modelo / Variação	MSE	RMSE	MAE
Baseline Vanilla (SGD)	0.5183	0.7199	0.5650
Baseline + Momentum ($\beta = 0.9$)	0.4359	0.6602	0.5189
Baseline + Reg. L1 ($\lambda = 10^{-5}$)	0.5316	0.7291	0.5715
Baseline + Reg. L2 ($\lambda = 10^{-6}$)	0.5295	0.7277	0.5691
Baseline + Dropout ($p_1 = 0.05$, $p_2 = 0.1$)	0.4623	0.6799	0.5280
Modelo Combinado	0.4248	0.6517	0.5131

Os resultados do conjunto de teste apresentam um comportamento parcialmente diferente daquele observado na validação. O Modelo Combinado apresentou o menor MAE no conjunto de teste (0.5131), seguido pelo modelo com *Momentum* (0.5189). O *Dropout* também apresentou desempenho inferior ao *Momentum*, mas superior aos modelos com L1 e L2 isoladamente.

Os modelos com L1 e L2 apresentaram MAE de teste ligeiramente superiores ao *baseline*, com valores de 0.5715 e 0.5691, respectivamente. Assim, com os parâmetros utilizados neste experimento, essas duas técnicas não produziram uma melhoria mensurável na generalização.

O *Momentum* apresentou uma redução do MSE de teste de aproximadamente 15,9% em relação ao *baseline*, enquanto o Modelo Combinado apresentou uma redução de aproximadamente 18,0%. Esses resultados indicam que, para a configuração experimental adotada, a alteração na dinâmica de otimização teve impacto mais evidente do que as regularizações L1 e L2 isoladas.

Por fim, avalia-se nas Figuras 7 e 8 os gráficos de paridade e de distribuição dos resíduos para os Modelos Baseline e Combinado.




Figure 7: Avaliação no teste (Modelo Baseline): Gráfico de Paridade e Distribuição de Resíduos.




Figure 8: Avaliação no teste (Modelo Combinado): Gráfico de Paridade e Distribuição de Resíduos.

Em ambas as figuras, observa-se que o *baseline* e o modelo combinado compartilham o mesmo padrão geral de erro, embora não sejam idênticos. Em ambos, os resíduos não se distribuem de forma aleatória em torno de zero, sendo eles majoritariamente positivos quando o modelo prevê valores baixos e majoritariamente negativos quando prevê valores altos, isto é, o modelo tende a subestimar no primeiro caso e a superestimar no segundo.

As diferenças entre os modelos aparecem na distribuição das previsões. No *baseline* (Figura 7), um grande número de amostras recebe previsões praticamente idênticas, embora seus valores reais sejam muito diferentes entre si, e as previsões ficam restritas a uma faixa mais estreita. O modelo combinado (Figura 8) espalha melhor as previsões ao longo de uma faixa mais ampla e apresenta essa concentração de forma menos acentuada, o que é compatível com seu menor MSE de teste na Tabela 3. Ainda assim, a tendência dos resíduos com o valor predito permanece nos dois modelos. Uma explicação plausível é a escassez de exemplos nas regiões extremas do alvo, dado que o treinamento usou apenas 30 amostras.

4. Discussão e Lições Aprendidas

4.1. Impacto do SGD Vanilla no Regime de Poucos Dados (10% de Treino):

A arquitetura da rede projetada possui mais de 16.000 parâmetros, um número desproporcional às 30 amostras de treino disponíveis, forçando o modelo a memorizar os dados de treino. O *baseline* reflete esse comportamento com clareza, apresentando um MSE de teste (0.5183) cerca de cinco vezes superior ao de treino. A principal lição extraída desse cenário de extrema escassez de dados é que as regularizações são necessárias para simplificar o modelo, de modo a ser mais generalizável a um novo conjunto do domínio.

4.2. Ação Específica dos Hiperparâmetros de Ablação

A inclusão do *momentum* acelerou a descida inicial da curva de perda, mas inseriu fortes picos de instabilidade, chegando a registrar um MSE entre 2 e 4 na validação. Embora não tenha antecipado a época de convergência ideal (menor *loss* de validação), obteve o maior ganho isolado do experimento, reduzindo o MSE de teste em 15,9%.

Ao contrapor L1 e L2, neste experimento, observou-se um desempenho virtualmente idêntico, com ambos convergindo exatamente na época 2611 e gerando métricas de teste quase idênticas. Conceitualmente, a regularização L1 costuma se destacar em cenários de alta dimensionalidade por realizar seleção de atributos (zerando pesos de variáveis irrelevantes), enquanto a L2 é indicada para penalizar pesos excessivamente grandes, suavizando as previsões do modelo.

O fato de ambas não apresentarem ganhos substanciais levanta algumas hipóteses atreladas à estrutura do problema: é possível que a L1 não tenha surtido efeito prático porque a rede possui apenas uma

dimensão de entrada, não havendo múltiplas *features* para serem selecionadas ou descartadas; já em relação à L2, uma possibilidade plausível é que a extrema superparametrização permita que a rede memorize os dados distribuindo o aprendizado entre milhares de pesos de magnitude muito baixa. Caso isso ocorra, o modelo conseguiria sobreajustar sem necessariamente inflar pesos individuais, o que tornaria a penalização da L2 ineficaz para frear a memorização.

O *dropout*, por sua vez, demonstrou empiricamente seu papel de regularização. Observou-se que houve uma diminuição na métrica de treino (com aumento de 18% no MSE) e um atraso substancial na convergência (alcançando o valor ótimo apenas na época 4786). Assim, a lição extraída é que simplificar a representação inicial do treinamento pode ajudar a rede a mapear características mais genéricas, garantindo um desempenho superior frente a dados inéditos.

Por fim, o Modelo Combinado fornece uma lição clara sobre a sobreposição de hiperparâmetros. Observou-se que os ganhos não são simplesmente aditivos. O *momentum* isolado foi responsável pela maior melhoria do experimento (queda de $\sim 16\%$ no MSE de teste). A L2, isolada, não apresentou ganhos reais sobre o *baseline*. Quando unidos, o Modelo Combinado obteve menores *losses*, mas obteve um ganho apenas marginal sobre o modelo contendo apenas *momentum*.

4.3. Análise de Resíduos e Limitações Estruturais

Como evidenciado na seção anterior, a análise visual confirmou que o modelo regularizado não superou as falhas estruturais nas caudas da distribuição. O padrão de superestimar valores muito negativos e subestimar valores altos persistiu de forma inalterada em ambas as abordagens.

A principal lição extraída é que esse viés não reflete um ajuste ruim de hiperparâmetros, mas sim um sintoma direto da escassez de dados. Com apenas 30 amostras de treino, a rede carece de representatividade nas extremidades do problema e acaba concentrando suas previsões em torno da média local. Fica demonstrado, portanto, que as técnicas de regularização podem ser eficazes para reduzir a magnitude do erro absoluto, mas não conseguem suprir a ausência de informação estrutural nem corrigir vieses derivados de amostragem insuficiente.