Projeto 3: VAE - *Variational Autoencoder*

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Vinícius Augusto Landim Andrade (RA: 169251)

Repositório / Código Reprodutível:

https://github.com/vinicius-landim/neural-networks-course/tree/main/project-3-VAE

1. Configuração Experimental

Este trabalho treina modelos generativos do tipo *Variational Autoencoder* (VAE) para o conjunto Fashion-MNIST e explora a organização do espaço latente aprendido. Foram consideradas duas configurações de espaço latente, com 2 e 8 dimensões, e, para cada uma, a topologia da rede foi escolhida pela menor função de custo no conjunto de validação.

1.1. Dados

O Fashion-MNIST contém 70.000 imagens em tons de cinza de 28×28 pixels, divididas em dez classes de peças de vestuário e acessórios: camiseta, calça, pulôver, vestido, casaco, sandália, camisa, tênis, bolsa e bota. Os pixels foram normalizados para o intervalo $[0, 1]$. As 60.000 imagens de treino originais foram separadas, de forma estratificada por classe, em 50.000 para treino e 10.000 para validação. As 10.000 imagens de teste foram usadas apenas na avaliação final e na análise do espaço latente. Os rótulos não são usados no treinamento, apenas na visualização e na análise.

1.2. Modelo e função de custo

O codificador recebe uma imagem $\mathbf{x}$ e produz os parâmetros de uma distribuição normal no espaço latente, a média $\boldsymbol{\mu}$ e o logaritmo da variância $\log \boldsymbol{\sigma}^2$, ambos com dimensão $d \in \{2, 8\}$. Um ponto latente é amostrado pelo método de reparametrização,

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\zeta}, \qquad \boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tag{1}$$

que mantém a amostragem derivável em relação a $\boldsymbol{\mu}$ e $\boldsymbol{\sigma}$. O decodificador reconstrói a imagem $\hat{\mathbf{x}}$ a partir de $\mathbf{z}$, com ativação sigmoide na saída para manter os pixels em $[0, 1]$. A função de custo, calculada por imagem, é a soma do erro de reconstrução com a divergência de Kullback-Leibler entre a distribuição do codificador e a distribuição a priori $\mathcal{N}(\mathbf{0}, \mathbf{I})$:

$$\mathcal{L} = \sum_{p=1}^{784} (x_p - \hat{x}_p)^2 \; - \; \frac{1}{2} \sum_{j=1}^{d} \left(1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2\right). \tag{2}$$

O primeiro termo favorece reconstruções fiéis, e o segundo aproxima as distribuições latentes de uma normal padrão, o que torna o espaço latente contínuo e permite gerar novas imagens decodificando amostras $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

1.3. Arquiteturas e treinamento

Foram comparadas três topologias para cada dimensão latente, resumidas na Tabela 1. Nas três, o decodificador espelha o codificador, e as ativações intermediárias são ReLU. No caso da rede convolucional, ela reduz a resolução pela metade a cada camada (*stride* 2) e usa convoluções transpostas no decodificador para retornar a 28×28.

Modelo	Codificador (decodificador espelhado)	Parâmetros ($d = 2$)
MLP padrão	$784 \to 256 \to d$	$\approx$ 404 mil
MLP profunda	$784 \to 512 \to 256 \to d$	$\approx$ 1,07 milhão
Convolucional	Conv(32) $\to$ Conv(64) $\to$ Densa(256) $\to d$	$\approx$ 1,68 milhão

Table 1: Topologias candidatas. Na convolucional, cada camada usa *kernel* 4×4 e *stride* 2 ($28 \times 28 \to 14 \times 14 \to 7 \times 7$).

Os seis modelos foram treinados com os mesmos hiperparâmetros, apresentados na Tabela 2. O treinamento foi interrompido quando a perda de validação não melhorou por cinco épocas consecutivas, e foram mantidos os pesos da melhor época. A evolução das perdas, das reconstruções e das imagens geradas foi acompanhada no TensorBoard.

Parâmetro	Valor
Otimizador	Adam
Taxa de aprendizado	10^{-3}
Tamanho do lote	128
Épocas (máximo)	50
Early stopping	paciência de 5 épocas, pela perda de validação
Semente aleatória	42

Table 2: Configuração do treinamento, comum a todos os modelos.

1.4. Análise do espaço latente

A representação latente de cada imagem de teste é a média $\boldsymbol{\mu}$ produzida pelo codificador, sem amostragem. O espaço latente 2D é visualizado diretamente, e o 8D é projetado em duas dimensões por Análise de Componentes Principais (PCA). A variância explicada pela projeção é $(\lambda_1+\lambda_2)/\sum_j \lambda_j$, em que λ_j são os autovalores da matriz de covariância das representações. Para quantificar a separação das classes, foi usado o coeficiente de silhueta calculado com os rótulos reais, que varia de -1 a 1: valores próximos de 1 indicam classes compactas e separadas, próximos de 0 indicam classes encostadas ou sobrepostas, e valores negativos indicam pontos mais próximos de outra classe do que da sua.

2. Seleção da Topologia

A Tabela 3 apresenta a perda de validação de cada candidato e a Figura 1 mostra a sua evolução durante o treinamento. A MLP profunda foi a melhor no espaço 2D e a rede convolucional no espaço 8D. Nas duas dimensões, a MLP padrão teve a maior perda, o que indica que uma única camada oculta limita a capacidade do modelo. Os dois modelos vencedores tiveram perdas de teste praticamente iguais às de validação (25,73 e 22,82), sem sinais de sobreajuste.

d	Modelo	Melhor época	Perda total	Reconstrução	KL
2	MLP padrão	36	27,77	22,84	4,93
	MLP profunda	50	**25,68**	20,47	5,21
	Convolucional	33	26,32	21,34	4,98
8	MLP padrão	47	23,96	16,04	7,92
	MLP profunda	39	22,92	15,44	7,48
	Convolucional	50	**22,68**	14,63	8,05

Table 3: Perda no conjunto de validação (média por imagem) para cada topologia e dimensão latente. Em negrito, o modelo escolhido.

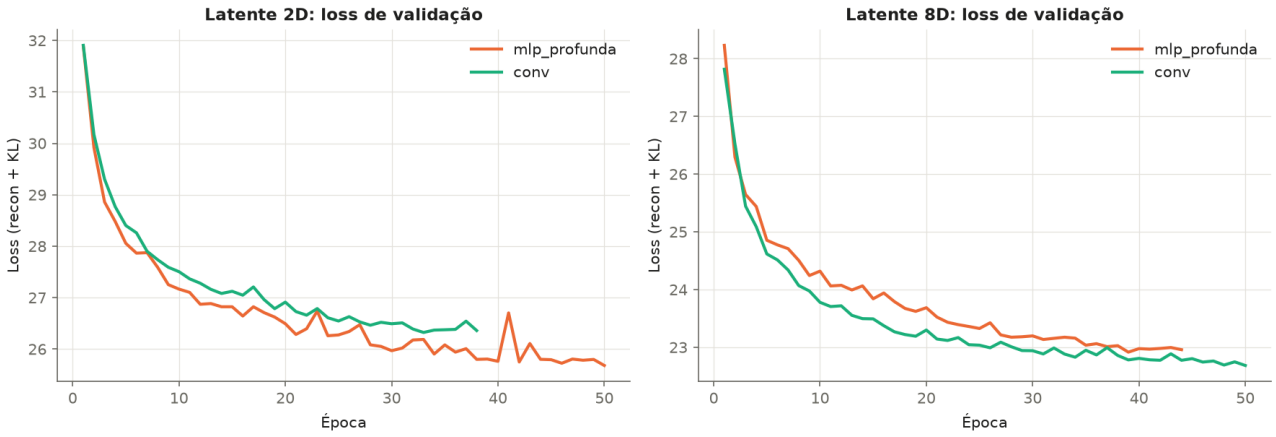


Figure 1: Evolução da perda de validação durante o treinamento, para cada dimensão latente.

A diferença entre os dois melhores candidatos foi pequena (0,64 no espaço 2D e 0,23 no 8D) e cada modelo foi treinado uma única vez, então a ordem entre a MLP profunda e a rede convolucional não é conclusiva. Além disso, os dois vencedores atingiram o limite de 50 épocas com a perda ainda em leve queda.

A comparação entre as dimensões mostra o compromisso entre os dois termos da Equação 2. Com 8 dimensões, o erro de reconstrução foi cerca de 30% menor, enquanto o termo KL aumentou. O espaço maior permite guardar mais informação sobre cada imagem, e o termo KL mede justamente essa quantidade de informação. Por isso, a perda total só é comparável entre modelos com a mesma dimensão latente.

3. Reconstrução e Geração

A Figura 2 compara uma imagem de cada classe do conjunto de teste com as reconstruções dos dois modelos escolhidos. Observe que os dois preservam a silhueta e o tom geral de cada peça, mas perdem os detalhes finos. Por exemplo, a estampa do pulôver e as listras do casaco desaparecem, e as peças ficam com textura uniforme. No caso da reconstrução com 8 dimensões o resultado foi um pouco mais nítido; como na bota, que no espaço 2D aparece mais clara e borrada.

Note também a presença do desfoque, que é um comportamento característico do VAE com erro quadrático, pois quando o decodificador não consegue distinguir entre variações parecidas, a saída que minimiza o erro é a média entre elas.



Figure 2: Imagens originais do conjunto de teste e reconstruções dos modelos escolhidos: MLP profunda (espaço latente 2D) e rede convolucional (espaço latente 8D).

A Figura 3 mostra imagens geradas a partir de pontos sorteados da distribuição a priori. Nos dois

modelos, a maior parte das amostras é uma peça reconhecível, e todas as categorias aparecem, o que indica que o espaço latente não tem grandes regiões sem significado. Algumas amostras, porém, são borradas ou parecem combinar duas classes, como um tênis que se confunde com uma bota ou uma camiseta com um vestido. Essas imagens correspondem a pontos nas regiões de transição entre classes, que existem porque o espaço latente é contínuo.

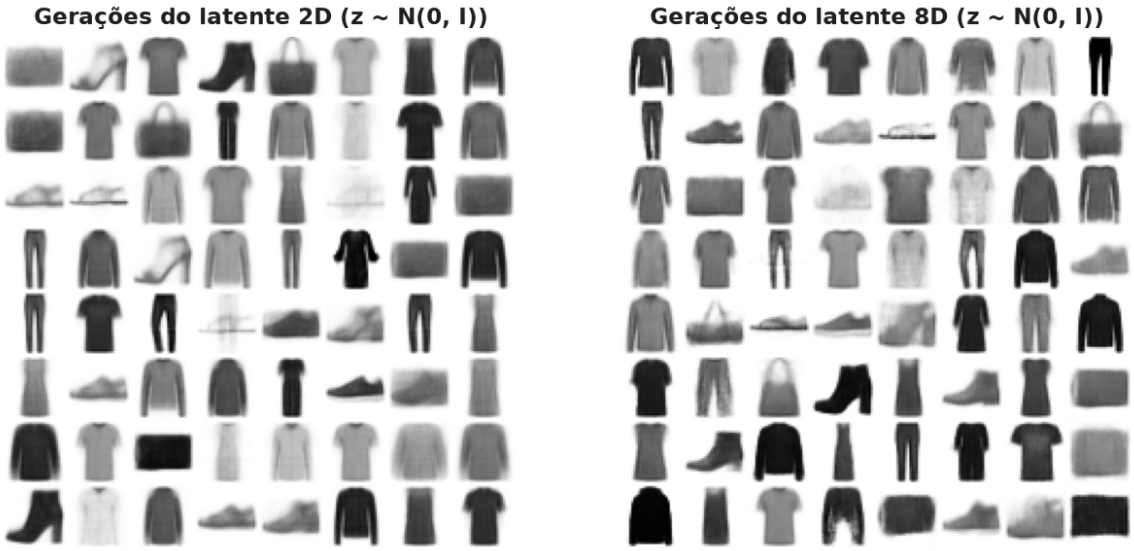


Figure 3: Imagens geradas a partir de $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ pelos modelos escolhidos: MLP profunda (espaço latente 2D) e rede convolucional (espaço latente 8D).

Um comportamente interessante que se pode obervar no acompanhamento pelo TensorBoard foi que, com os mesmos pontos latentes decodificados, nas primeiras épocas uma mesma amostra podia mudar de categoria antes de se estabilizar. Isso ocorre porque o significado de cada região do espaço latente não é fixo, já que o termo KL restringe apenas a distribuição global dos pontos, e a posição de cada classe se reorganiza enquanto o modelo aprende primeiro as diferenças mais gerais (por exemplo, calçados contra roupas) e depois as mais finas.

4. Espaço Latente 2D

A Figura 4 mostra a representação latente das imagens de teste no modelo 2D, e a Figura 5 destaca cada classe em um painel separado. Os pontos formam uma única nuvem contínua centrada na origem, sem regiões vazias entre as classes, e as classes se distribuem como setores radiais a partir do centro. Esse formato é consequência do termo KL, que puxa todas as distribuições para perto da normal padrão.

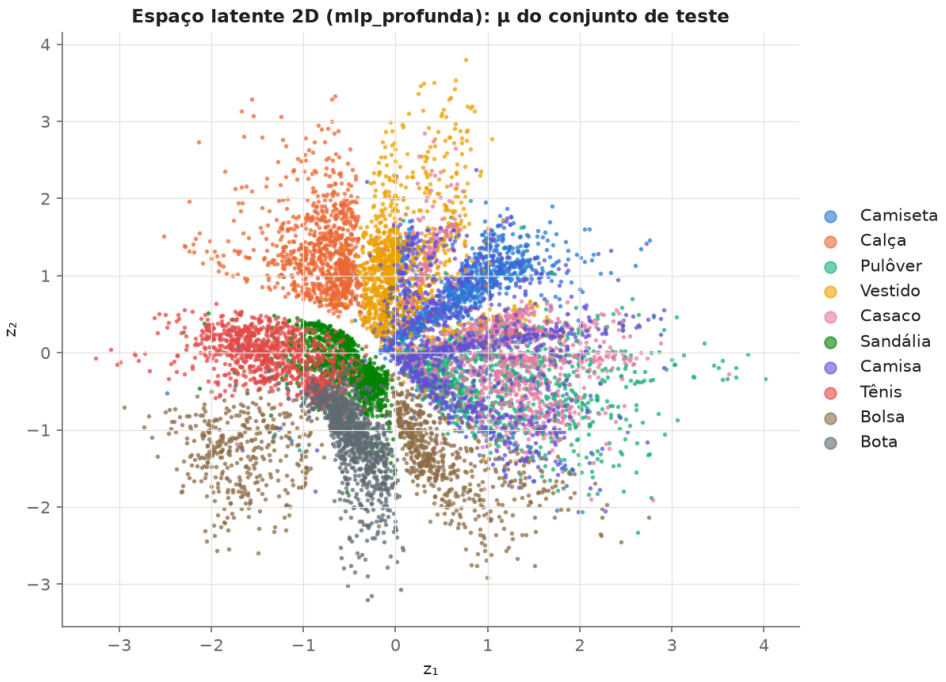


Figure 4: Espaço latente 2D (MLP profunda): média $\boldsymbol{\mu}$ de cada imagem do conjunto de teste, colorida pelo rótulo.

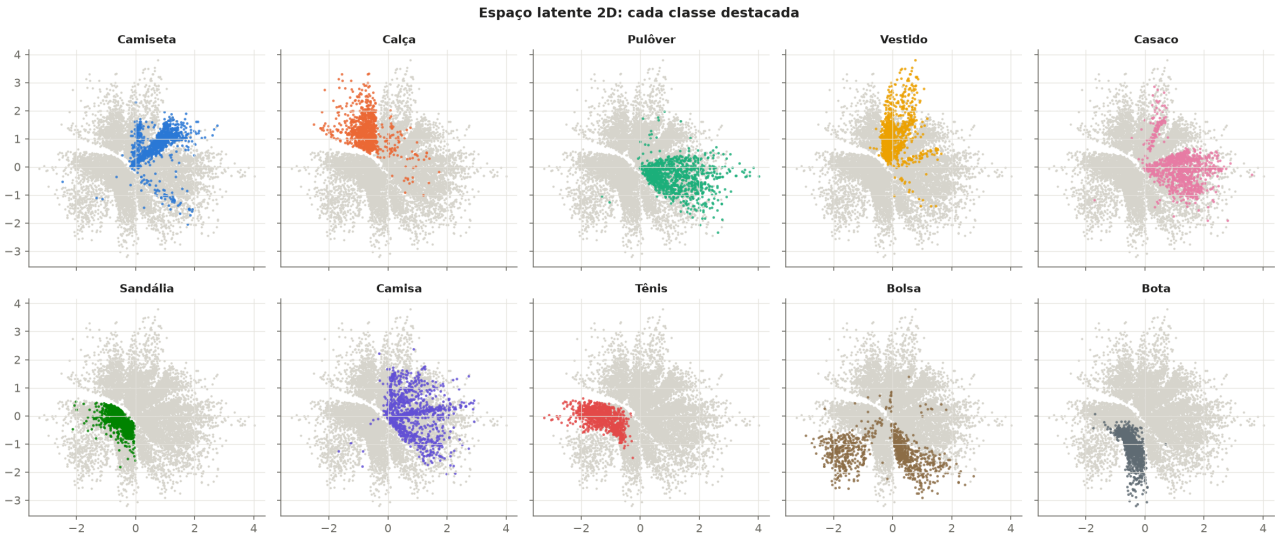


Figure 5: Espaço latente 2D com cada classe destacada sobre as demais.

Apesar de não terem sido usados no treinamento, os rótulos aparecem organizados por semelhança visual. Com essa análise, é possível entender a concentração de pontos que engloba cada classe e, principalmente, observar a aproximação de *clusters* entre classes com semelhança semântica.

Observe o caso dos três calçados (sandália, tênis e bota), em que eles ocupam setores vizinhos e compactos à esquerda e abaixo da origem. O mesmo ocorre para as quatro peças de vestimenta superior (camiseta, pulôver, casaco e camisa), que ocupam a mesma região e se sobrepõem bastante, em especial a camisa, que se espalha sobre as outras três. Em 28×28 pixels e sem cor, essas peças diferem apenas em detalhes como o comprimento da manga e a presença de botões ou gola.

A bolsa é a única classe dividida em dois grupos separados, abaixo da origem. O mapa da Figura 6 indica o motivo: um grupo corresponde a bolsas retangulares sem alça, e o outro a bolsas com alça. O modelo encontrou uma subdivisão da classe que os rótulos não registram.

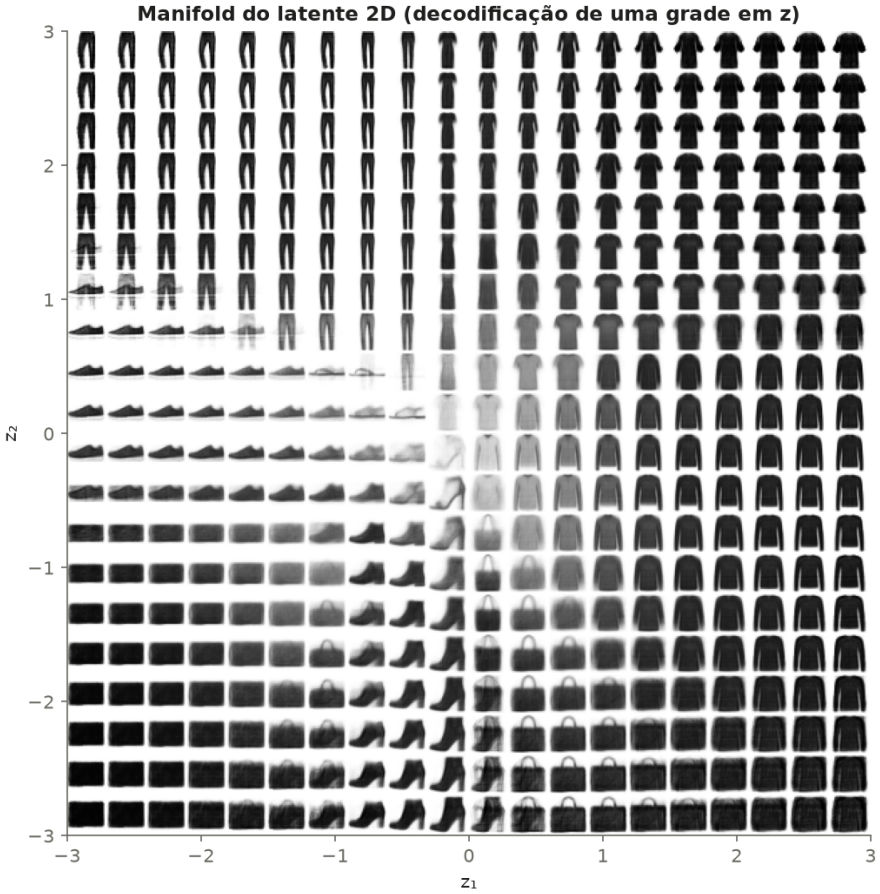


Figure 6: Imagens decodificadas a partir de uma grade de pontos no espaço latente 2D, com $z_1, z_2 \in [-3, 3]$.

A Figura 6 mostra o espaço latente pelo lado do decodificador. As regiões do mapa correspondem às da Figura 4: calças no canto superior esquerdo, camisetas no superior direito, peças de manga longa à direita, tênis à esquerda e bolsas e botas na parte inferior. As transições entre regiões são graduais, como a calça que se estreita até virar vestido e depois se alarga até virar camiseta, ou o tênis que ganha cano e salto até virar bota. Não há regiões que decodifiquem em ruído, o que confirma que o espaço é contínuo. Nas bordas da grade, que correspondem a pontos pouco prováveis pela distribuição a priori, as imagens tendem a ficar mais escuras e exageradas.

5. Espaço Latente 8D e Projeção por PCA

A Figura 7 mostra a variância explicada por cada componente principal das representações 8D. A projeção nas duas primeiras componentes explica 41,7% da variância. As seis primeiras componentes têm autovalores entre 0,39 e 1,04, e as duas últimas têm variância praticamente nula. Isso indica que duas das oito dimensões latentes não foram usadas pelo modelo, um fenômeno conhecido como colapso posterior, em que o codificador mantém essas dimensões iguais à distribuição a priori para não pagar o custo do termo KL. Nas dimensões usadas, os autovalores próximos de 1 são esperados, pois o termo KL aproxima cada dimensão de uma normal padrão. Como consequência, a variância fica distribuída quase igualmente entre as componentes, e nenhuma projeção em duas dimensões consegue representar a maior parte dela.

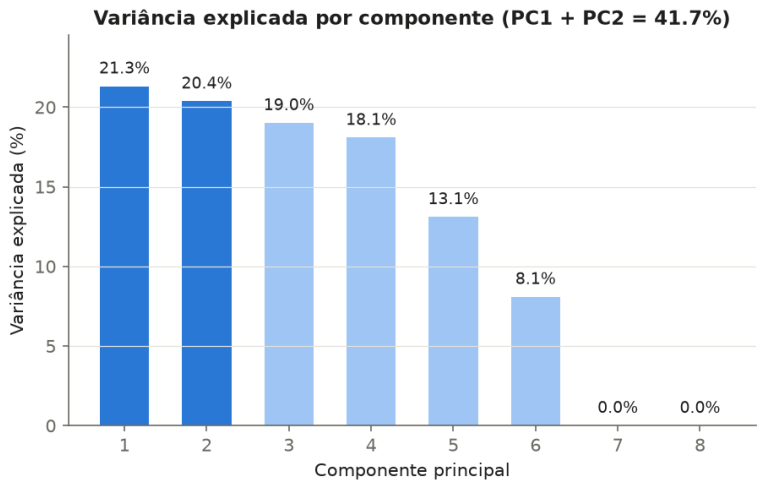


Figure 7: Variância explicada por componente principal do espaço latente 8D.

As Figuras 8 e 9 mostram a projeção do espaço 8D. A estrutura é a mesma observada no espaço 2D: uma nuvem contínua, com os calçados agrupados em uma região, a calça e o vestido em outra, a bolsa entre os calçados e as peças de parte superior sobrepostas. Nesta projeção, a bolsa aparece como um único grupo alongado, e a separação em dois estilos não é visível. As mesmas relações de vizinhança surgiram nos dois modelos, com topologias e dimensões diferentes, o que indica que elas refletem a semelhança visual entre as peças, e não uma particularidade de um treinamento.

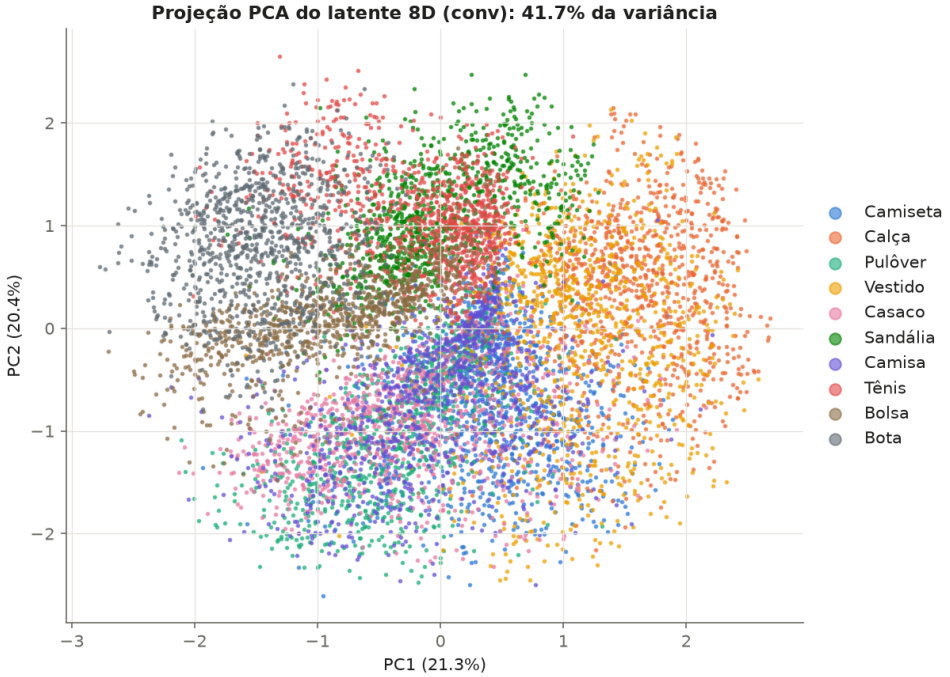


Figure 8: Projeção do espaço latente 8D (rede convolucional) nas duas primeiras componentes principais, colorida pelo rótulo.

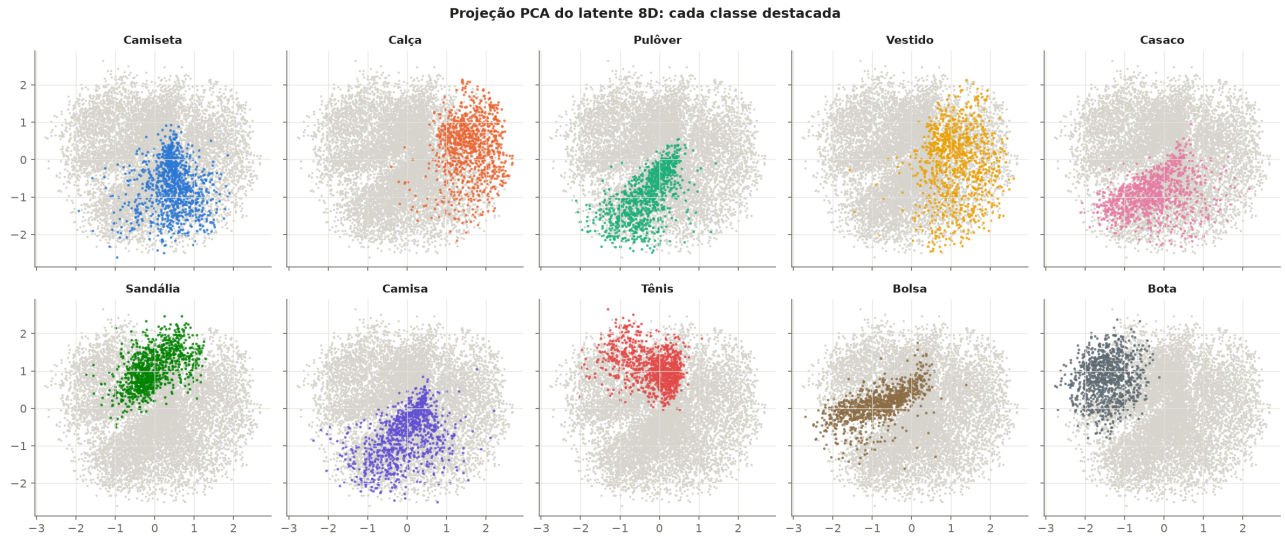


Figure 9: Projeção PCA do espaço latente 8D com cada classe destacada sobre as demais.

A projeção perde parte da separação existente no espaço completo. O coeficiente de silhueta médio foi de 0,053 no espaço 8D e caiu para −0,004 na projeção, e na projeção as classes se sobrepõem mais do que no espaço latente 2D treinado diretamente (silhueta de 0,056). Parte da distinção entre as classes está, portanto, nas componentes que a projeção descarta.

6. Resultados e Discussão

Há formação de clusters no espaço latente? Não na forma de grupos isolados. Nos dois espaços, as representações formam uma nuvem contínua em torno da origem, e o coeficiente de silhueta ficou próximo de zero (0,056 no 2D e 0,053 no 8D). O que se observa são regiões mais densas e grupos de classes vizinhas. Esse resultado é coerente com o funcionamento do VAE: o termo KL aproxima as distribuições de todas as imagens da mesma normal padrão, o que as faz se sobrepor e elimina os espaços vazios. É essa mesma propriedade que permite gerar imagens a partir de qualquer ponto e obter transições suaves entre peças.

Há separação dos rótulos no espaço latente? Parcialmente, e de acordo com a semelhança visual. Os calçados, a calça e a bolsa ocupam regiões próprias, enquanto camiseta, pulôver, casaco e camisa se sobrepõem, com a camisa com silhueta negativa nas três representações. O espaço latente foi organizado sem acesso aos rótulos e, por isso, reflete a aparência das imagens e não a divisão em classes: peças parecidas ficam próximas mesmo quando têm rótulos diferentes, e uma classe com estilos visualmente distintos, como a bolsa, pode ser dividida. O coeficiente de silhueta deve ser lido com essa ressalva, pois penaliza tanto classes encostadas quanto classes divididas em subgrupos.

A projeção ilustra quanto da variância? A projeção do espaço 8D nas duas primeiras componentes principais ilustra 41,7% da variância. O valor é baixo porque o modelo distribuiu a informação de forma quase uniforme entre as seis dimensões que usou, e porque o termo KL tende a igualar a variância das dimensões. A projeção mostra os mesmos grupos de vizinhança do espaço 2D, mas com mais sobreposição.

Os resultados devem ser lidos com algumas ressalvas. Cada modelo foi treinado uma única vez, com semente fixa, e os hiperparâmetros não foram variados, então a diferença entre a MLP profunda e a rede convolucional pode não se repetir. Os modelos escolhidos também atingiram o limite de épocas. Em conclusão, os VAEs aprenderam espaços latentes contínuos e organizados por semelhança visual, capazes de gerar peças reconhecíveis. O espaço 2D permite visualização direta e interpretação do mapa gerativo, mas força mais sobreposição; o espaço 8D reconstrói melhor, mas só pode ser visto por uma projeção que mostra menos da metade da sua variância.